MANUAL DE USO

Para la creación del cluster de Spark es necesario que los workers tengan comunicación con el master. Para tal fin se deben cumplir dos condiciones:

- El *master* (Servidor) debe vincularse con una interfaz, IP o nombre accesible desde los *workers (Clientes)*.
- Los *workers* deben disponer de la IP del *master* o un nombre que resuelva correctamente a dicha IP, así como conectividad con el mismo.

La dirección de vinculación se le proporciona al *master* a través de la variable de entorno SPARK_MASTER_HOST. Por defecto la imagen tiene un valor de *spark-master*.

La dirección del *master* se le proporciona a cada *worker* a través de la variable de entorno SPARK_MASTER_URL. Por defecto la imagen tiene un valor de*spark://spark-master:7077*.

Para que los contenedores resuelvan el nombre *spark-master* a la IP correcta hay que apoyarse en el servidor DNS para redes definidas por el usuario, una característica introducida a partir de la version 1.10 de Docker Engine. Este servidor DNS proporciona una función de descubrimiento de servicios para cualquier contenedor creado con un nombre o net-alias válido. Las redes definidas por el usuario son redes virtuales que permiten agrupar los contenedores en subredes, según las preferencias del usuario.

Antes de iniciar se debe configurar la red que albergará al cliente y los equipos que servirán de estaciones, la red definida por el usuario se nombrará *sparknet*, y se debe instanciar un contenedor Spark *master* y dos contenedores Spark *workers*.

```
# Se crea la red
docker network create sparknet
# Se ejecuta en el puerto 8080
docker run -d --net=sparknet -p 8080:8080 --name spark-master gradiant/spark:2.0.0 master
# Se crean las estaciones de trabajo y se indica que es un cliente del servidor
docker run -d --net=sparknet --name spark-worker1 gradiant/spark:2.0.0 worker
docker run -d --net=sparknet --name spark-worker2 gradiant/spark:2.0.0 worker
```

Para comprobar que la resolución de nombres funciona correctamente y existe conectividad entre los *workers* y el *master* se puede ejecutar un comando ping en cada contenedor:

```
# Se ejecuta el servidor y se hace un ping al mismo.
docker exec spark-master ping -c 1 spark-master

# Ping desde el cliente hacía el servidor
docker exec spark-worker2 ping -c 1 spark-master
docker exec spark-worker2 ping -c 1 spark-master
```

Es posible utilizar nombres personalizados para los contenedores. Solo es necesario sobrescribir las variables de entorno que proporcionan a Spark el nombre del contenedor *master*, por ejemplo:

#Cambiar el nombre del servidor

docker run -d --net=sparknet --name maestro -e SPARK_MASTER_HOST=maestro gradiant/spark:2.0.0 master

#Cambiar el nombre del cliente o estaciones de trabajo.

docker run -d --net=sparknet --name esclavo -e SPARK_MASTER_URL=spark://maestro:7077 gradiant/spark:2.0.0 worker

Accediendo a la interfaz de usuario de Spark puede comprobarse el estado de*master* y *workers*:

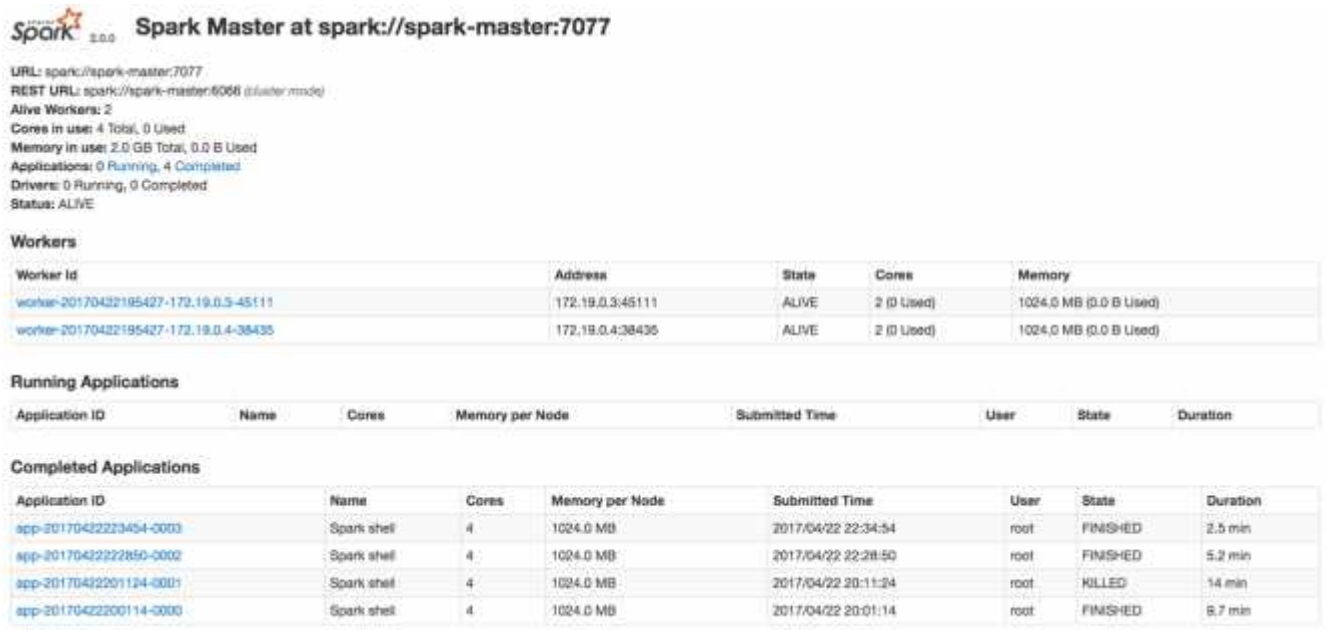

INICIAR

#Ruta del directorio

cd spark-2.0.0-bin-hadoop2.7/

Iniciar Servidor

docker start spark-master

#Iniciar Clientes

docker start spark-worker1

docker start spark-worker2

#Iniciar Shell del Cliente

docker exec -it spark-worker1 bash

Servidor Local

spark-shell --master spark://spark-master:7077

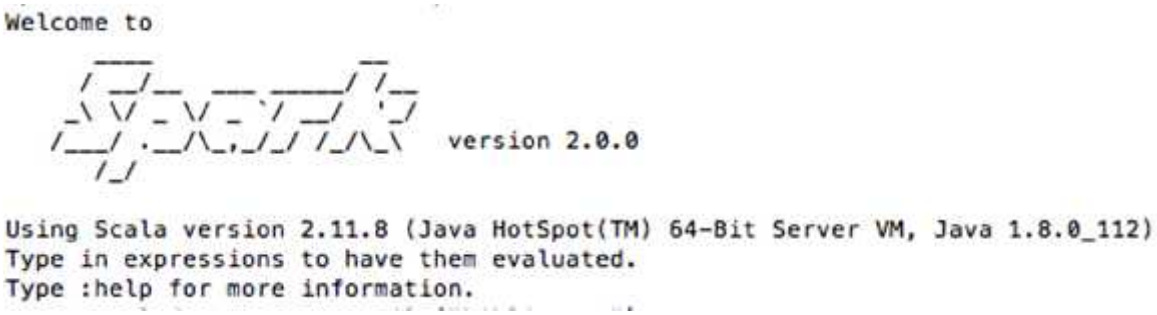

EJEMPLO: Contar el número de palabras con más coincidencias dentro de un texto

```
val docs = sc.textFile("biblia.txt")

val lower=docs.map(line => line.toLowerCase)

val stopwords=Set("the","of","my")

words =lower.flatMap(line => line.split("\\s+")).filter(! stopwords.contains(_))

val counts=words.map(word =>(word,1))

val freq =counts.reduceByKey(_ + _)
```

#Resultado

```
(51380,and)
(25295,)
(13643,to)
(12799,that)
(12560,in)
(10263,he)
(9840,shall)
(8987,unto)
(8836,for)
(8708,i)
(8450,his)
(8232,a)
(7300,they)
(6877,is)
(6873,be)
(6049,with)
(5904,not)
(5450,all)
(5202,thou)
(4739,lord)
```